

Antwortbericht (GraphRAG)

Datum: 2025-08-18 12:13

Frage

Erkläre das Konzept von RAG mit Belegen.

Antwort (mit Belegen)

Das Konzept von Retrieval-Augmented Generation (RAG) bezieht sich auf die Methode, bei der ein Modell, bevor es Fragen beantwortet oder Text generiert, relevante Informationen aus einem umfangreichen Dokumentenkörper abruft. Diese abgerufenen Informationen werden dann genutzt, um die Qualität der generierten Antworten oder Texte zu verbessern. Dies ermöglicht es Entwicklern, das gesamte große Modell nicht für jede spezifische Aufgabe neu trainieren zu müssen. Stattdessen kann eine Wissensbasis angehängt werden, die dem Modell zusätzliche Informationen liefert und die Genauigkeit seiner Antworten verbessert. RAG-Methoden sind besonders gut für wissensintensive Aufgaben geeignet [P5baf0fb-2468-496c-b3ce-261ff4c86f13].

RAG kombiniert das parametrisierte Wissen von großen Sprachmodellen (LLMs) mit nicht-parametrisiertem externen Wissen. Dies verbessert die Genauigkeit der Antworten erheblich, reduziert Halluzinationen des Modells und ist besonders nützlich für wissensintensive Aufgaben. Durch das Zitieren von Quellen können Benutzer die Genauigkeit der Antworten überprüfen und das Vertrauen in die Modellausgaben erhöhen. RAG erleichtert auch das Aktualisieren von Wissen und die Einführung von domänenspezifischem Wissen [Peea6b4f3-47f7-4716-ba51-34858b8d1fef].

Die Entwicklung des RAG-Forschungsparadigmas wird in drei Typen unterteilt: Naive RAG, Advanced RAG und Modular RAG. Naive RAG, das früheste Paradigma, umfasst die traditionellen Prozesse des Indexierens, Abrufens und Generierens und wird auch als "Retrieve"- "Read"-Framework zusammengefasst [P1ddbbb7b-f090-4393-8ddf-f81905c145b1, Pc6285a81-7189-42f4-ae16-4a703e86bcda].

Quellen:


- [P5baf0fb-2468-496c-b3ce-261ff4c86f13] — DOI: <doi> — URL: <https://github.com/Tongji-KGLLM/> — Seite: 3 — Abschnitt: RAG vs Fine-tuning
- [Peea6b4f3-47f7-4716-ba51-34858b8d1fef] — DOI: <doi> — URL: <https://github.com/Tongji-KGLLM/> — Seite: 1 — Abschnitt: Introduction
- [P1ddbbb7b-f090-4393-8ddf-f81905c145b1] — DOI: <doi> — URL: <https://github.com/Tongji-KGLLM/> — Seite: 4 — Abschnitt: RAG Framework
- [Pc6285a81-7189-42f4-ae16-4a703e86bcda] — DOI: <doi> — URL: <https://github.com/Tongji-KGLLM/> — Seite: 5 — Abschnitt: Indexing

Quellen

- [P5baf0fb-2468-496c-b3ce-261ff4c86f13] — DOI: — URL: <https://github.com/Tongji-KGLLM/> — Seite: 3 — Abschnitt: RAG vs Fine-tuning

- [Pea3105a5-3bc5-4a7e-acc5-6281b9428f58] — — DOI: — — URL: <https://github.com/Tongji-KGLLM/> — Seite: 15 — Abschnitt: Fine-tuning Stage
- [P4c340c63-53ac-4401-9994-0f2144f0dcb8] — — DOI: — — URL: <https://github.com/Tongji-KGLLM/> — Seite: 9 — Abschnitt: New Pattern
- [P99745326-a458-48f9-a09c-486c1f01cfd5] — — DOI: — — URL: <https://github.com/Tongji-KGLLM/> — Seite: 3 — Abschnitt: RAG vs Fine-tuning
- [F537f9a4a-80e1-4967-9dff-369a86404234] — — DOI: — — URL: <https://github.com/Tongji-KGLLM/> — Seite: 9 — Abschnitt: New Pattern
- [P7b21dd26-e4be-4cd5-b29a-28b7512dbbd5] — — DOI: — — URL: <https://github.com/Tongji-KGLLM/> — Seite: 3 — Abschnitt: RAG vs Fine-tuning
- [P1ddbbb7b-f090-4393-8ddf-f81905c145b1] — — DOI: — — URL: <https://github.com/Tongji-KGLLM/> — Seite: 4 — Abschnitt: RAG Framework
- [Pc6285a81-7189-42f4-ae16-4a703e86bcda] — — DOI: — — URL: <https://github.com/Tongji-KGLLM/> — Seite: 5 — Abschnitt: Indexing
- [Peea6b4f3-47f7-4716-ba51-34858b8d1fef] — — DOI: — — URL: <https://github.com/Tongji-KGLLM/> — Seite: 1 — Abschnitt: Introduction
- [Pd5899655-a051-4636-8080-fd0b769211c9] — — DOI: — — URL: <https://github.com/Tongji-KGLLM/> — Seite: 9 — Abschnitt: New Pattern
- [P2033b9db-4b15-4032-aecc-9c735efe5850] — — DOI: — — URL: <https://github.com/Tongji-KGLLM/> — Seite: 14 — Abschnitt: Pre-training Stage
- [P543042a5-66e4-4340-98d5-622c7f3d46a3] — — DOI: — — URL: <https://github.com/Tongji-KGLLM/> — Seite: 5 — Abschnitt: Indexing

Verwendete Abbildungen (Top 1)



[F537f9a4a-80e1-4967-9dff-369a86404234] ``json { "caption": "Diagramm, das die Entwicklung von Naive RAG zu Advanced RAG und Modular RAG zeigt.", "figure_type": "diagram", "entities": ["Naive RAG", "Advanced RAG", "Modular RAG", "User", "Query", "Documents", "Vector Database", "Related Document Chunks", "Prompt", "LLM", "Pre-Retrieval", "Post-Retrieval", "New Modules", "New Patterns"], "ocr_hints": ["Naive RAG", "Advanced RAG", "Modular RAG", "Pre-Retrieval", "Post-Retrieval"] } `` (Seite 9)